

Comparação de Algoritmos de ML para Detecção de Malware Android

Estudo empírico com o dataset TUANDROMD · 10-fold CV estratificado

Fernando Pinéo de Abreu

Universidade de São Paulo · N° USP: 17989742

Random Forest

SVM

KNN

Árvore de Decisão

1. PROBLEMA

Motivação e Questão de Pesquisa

3B+

dispositivos Android ativos

79,8%

das amostras são malware

241

features binárias

QUESTÃO DE PESQUISA

Qual algoritmo — RF, SVM, KNN ou AD — apresenta maior F1 e AUC-ROC, e as diferenças são estatisticamente significativas sob 10-fold CV?

2. DATASET E METODOLOGIA

TUANDROMD + Protocolo Experimental

DATASET


- 4.464 instâncias · 241 features binárias
- 213 permissões Android + 28 APIs
- ! 3.802 duplicatas — cautela nas métricas
- ! Desbalanceamento: 79,8% malware

PROTOCOLO

- StratifiedKFold 10 folds, seed=42
- MinMaxScaler apenas em SVM e KNN
- Métricas: F1-score e AUC-ROC
- Wilcoxon + Bonferroni ($\alpha = 0,0083$)

3. RESULTADOS

F1-score e AUC-ROC por Algoritmo (média $\pm \sigma$)



🏆 Random Forest

F1 = **0,9969** · AUC = **0,9995**
 $\sigma_{\text{AUC}} = \pm 0,0006$ — mais estável

⚠️ Árvore de Decisão


F1 alto, AUC = **0,9819**
 $\sigma_{\text{AUC}} = \pm 0,0127$ — instável

SVM e KNN

Desempenho intermediário e similar entre si

3. RESULTADOS

Distribuição do F1-score nos 10 Folds



RF é o mais consistente


Caixa estreita — menor dispersão interquartil nos 10 folds.

AD tem outlier

Um fold distante revela sensibilidade à partição dos dados.

A variabilidade distingue RF dos demais — não apenas a mediana.

Wilcoxon Pareado + Correção de Bonferroni ($\alpha = 0,0083$)



PAR	P-VALOR	SIG.
RF vs SVM	0,002	Sim ✓
RF vs KNN	0,002	Sim ✓
RF vs AD	0,004	Sim ✓
SVM vs KNN	0,008	Sim ✓
SVM vs AD	0,695	Não X
KNN vs AD	0,051	Não X

RF supera todos com significância. SVM, KNN e AD não se distinguem entre si.

5. CONCLUSÃO

Síntese

O Random Forest obteve $F1 = 0,9969$ e $AUC = 0,9995$, com superioridade estatisticamente significativa sobre todos os demais após correção de Bonferroni ($p \leq 0,004$).

4/6

pares com diferença significativa

Cautela

3.802 duplicatas podem inflar métricas

Próximos

Grid search + SMOTE + datasets independentes