

Comparação de Algoritmos de ML para Detecção de Malware Android

Estudo empírico com o dataset TUANDROMD · 10-fold CV estratificado

Fernando Pinéo de Abreu

Universidade de São Paulo · N° USP: 17989742

Random Forest

SVM

KNN

Árvore de Decisão

1. PROBLEMA

Motivação e Questão de Pesquisa

3B+

dispositivos Android ativos

79,8%

das amostras são malware

24I

features binárias

QUESTÃO DE PESQUISA

Qual algoritmo — RF, SVM, KNN ou AD — apresenta maior F_1 e AUC-ROC, e as diferenças são estatisticamente significativas sob 10-fold CV?

2. DATASET E METODOLOGIA

TUANDROMD + Protocolo Experimental

DATASET

- 4.464 instâncias · 241 features binárias
- 213 permissões Android + 28 APIs
- ! 3.802 duplicatas — cautela nas métricas
- ! Desbalanceamento: 79,8% malware

PROTOCOLO

- StratifiedKFold 10 folds, seed=42
- MinMaxScaler apenas em SVM e KNN
- Métricas: F1-score e AUC-ROC
- Wilcoxon + Bonferroni ($\alpha = 0,0083$)

Objetivo da validação: estimar o erro fora da amostra; a escolha de modelos e hiperparâmetros no mesmo processo pode introduzir viés otimista leve.

Condições, Fatores e Controle Experimental

Condições testadas

RF, SVM, KNN e AD avaliados no mesmo conjunto TUANDROMD, com F1-score e AUC-ROC como resposta experimental.

Fatores manipulados

Hipótese/modelo de classificação e pré-processamento específico (MinMaxScaler apenas para SVM/KNN).

Constantes e bloqueio

Mesmos folds estratificados (pareamento), seed fixa, mesmas métricas e mesmo protocolo estatístico (Wilcoxon pareado + Bonferroni).

Este desenho busca estimar erro fora da amostra com menor viés e menor dependência de uma partição específica.

2.2 BASE DE DADOS (VISUAL)

Recorte do TUANDROMD em formato tabular

[illegible]

Leitura do recorte


Cada linha representa um aplicativo; as colunas são permissões e APIs codificadas de forma binária (0/1).

Ponto metodológico

A estrutura alta dimensional (241 features) motiva comparar algoritmos com vieses indutivos distintos sob o mesmo protocolo.

3. RESULTADOS

Taxa de Presença das Top 5 Features por Classe



Feature mais discriminativa

RECEIVE_BOOT_COMPLETED aparece em **98%** dos malwares e **39%** dos goodwares.


Padrão de benignidade

openConnection e getLastKnownLocation predominam em goodware.

O gráfico contextualiza por que os modelos conseguem separar classes com alto F1 e AUC.

3. RESULTADOS

F1-score e AUC-ROC por Algoritmo (média $\pm \sigma$)



🏆 Random Forest

F1 = **0,9969** · AUC = **0,9995**

$\sigma_{AUC} = \pm 0,0006$ — mais estável

⚠️ Árvore de Decisão

F1 alto, AUC = **0,9819**


$\sigma_{AUC} = \pm 0,0127$ — instável

SVM e KNN

Desempenho intermediário e similar entre si

3. RESULTADOS

Distribuição do F1-score nos 10 Folds



RF é o mais consistente

Caixa estreita — menor dispersão interquartil nos 10 folds.

AD tem outlier

Um fold distante revela sensibilidade à partição dos dados.

A variabilidade distingue RF dos demais — não apenas a mediana.

Wilcoxon Pareado + Correção de Bonferroni ($\alpha = 0,0083$)

	RF	SVM	KNN	AD
RF	—	p=0.002 ✓	p=0.002 ✓	p=0.004 ✓
SVM	p=0.002 ✓	—	p=0.008 ✓	p=0.695 ✗
KNN	p=0.002 ✓	p=0.008 ✓	—	p=0.051 ✗
AD	p=0.004 ✓	p=0.695 ✗	p=0.051 ✗	—

■ Azul = sig. ($p < 0,0083$) ■ Vermelho = n.s.

PAR	P-VALOR	SIG.
RF vs SVM	0,002	Sim ✓
RF vs KNN	0,002	Sim ✓
RF vs AD	0,004	Sim ✓
SVM vs KNN	0,008	Sim ✓
SVM vs AD	0,695	Não ✗
KNN vs AD	0,051	Não ✗

RF supera todos com significância. SVM, KNN e AD não se distinguem entre si.

5. LIMITAÇÕES

Ameaças à validade dos resultados

Muitas duplicatas no dataset

3.802 de 4.464 instâncias são duplicadas, podendo inflar F1/AUC e reduzir a variabilidade observada.

Desbalanceamento de classes

Com 79,8% de malware, os modelos podem favorecer a classe majoritária sem refletir cenários reais.

Validação em base única

Resultados obtidos apenas no TUANDROMD; a generalização para outros períodos e famílias é limitada.

Sem otimização extensa

Comparação focou configurações padrão; ajustes de hiperparâmetros e nested CV podem alterar o ranking.

6. CONCLUSÃO

Síntese

*O **Random Forest** obteve $F1 = 0,9969$ e $AUC = 0,9995$, com superioridade estatisticamente significativa sobre todos os demais após correção de Bonferroni ($p \leq 0,004$).*

4/6

pares com diferença significativa

Cautela

3.802 duplicatas podem inflar métricas

Próximos

Grid search + SMOTE + datasets independentes

7. ENCERRAMENTO

Obrigado!

Agradeço pela atenção.

Fernando Pinéo de Abreu